# Поиск выбросов и аномалий

1. Поиск выбросов (outlier detection). Есть множество объектов $M$. Найти в нем все аномальные объекты.

2. Поиск новизны (novelty detection). Есть множество объектов $M$. Определить, является ли объект $A \notin M$ похожим на объекты из $M$ или нет?

## Отличие выбросов от новизны и пропусков

Выброс – это часто реально существующий объект, но обладающий аномальными свойствами, он сильно отличается от других объектов выборки.

**Новизна** считается по отношению к старой выборке объектов. А выброс является аномальным уже для своих «соседей» по выборке.

# Примеры выбросов

1. Если наугад измерять температуру предметов в комнате, получим цифры от 18 до 22°С, но радиатор отопления будет иметь температуру в 70°  и это выброс, не типичное значение!

## Зачем нужно искать и уничтожать выбросы?

1. Если данные будут использоваться при решении задачи
   предсказания, то удаление выбросов, как правило, повышает точность предсказания (ибо правило «мусор на входе – мусор на выходе» никто не отменял).
2. Удаление выбросов позволяет получить нормальные
   (типичные, эталонные) объекты.
3. Многие характеристики (например, среднее значение) очень чувствительны к наличию выбросов.

# Идеальных методов обнаружения выбросов не бывает потому, что

1 не существует формального определения выброса.
2 алгоритм, беспощадный к выбросам, будет удалять и часть «нормальных» объектов.
3 алгоритм, гуманный к «нормальным» объектам, будет пропускать часть выбросов.

Построить идеальный детектор выбросов – это всё равно что предложить мед. анализ без ложноположительных и ложноотрицательных результатов.

# Методы обнаружения выбросов

I. Поиск аномальных объектов с помощью здравого смысла. Например, если известен нормальный диапазон для значений признака.

**Пример**: человек с ростом более 200 см (такие люди могут в реальности существовать, но их очень мало).

# Методы обнаружения выбросов

II. Методы, основанные на анализе одного признака (каждый признак берётся отдельно и ищутся объекты аномальными значениями этого признака).

III. Методы, основанные на одновременном анализе нескольких признаков.

# Методы, анализирующие признаки по отдельности

# Методы, анализирующие один признак

Пусть заданы значения признака

$$P = (p_1, p_2, \dots, p_n)$$

**Основная идея поиска аномалий:**
найти значения $p_i$, расположенные вдали от среднего значения (медианы).
Далее используем обозначения:
$\bar{P}$ - среднее значение, $n$ - объем выборки,
$S_P$ - отклонение

# Простейшие методы

1. Удалить все объекты, у которых величина $|p_i - \bar{p}|$ слишком велика.
2. Удалить все объекты, у которых величина $\frac{|p_i - \bar{p}|}{S_P}$ слишком велика.
3. Более продвинутый критерий Шовене
4. Определение выбросов без использования среднего и отклонения.

# Самое простое правило для определения выброса

1. Пусть *x* – подозрительное значение.
2. Исключим *x* из выборки и по оставшимся элементам вычислим среднее $\bar{p}$ и отклонение $s_P$.
3. Если выборка симметричная, то *x* будет выбросом, если он не принадлежит интервалу

$$(\bar{p} - 3s_P, \bar{p} + 3s_P)$$

4. Если выборка не симметричная, то *x* будет выбросом, если он не принадлежит интервалу

$$(\bar{p} - 5s_P, \bar{p} + 5s_P)$$

# Критерий Шовене (Chauvenet)

# Критерий Шовене (Chauvenet)

Значение $p_i$ является выбросом, если выполнено неравенство

$$erfc\left(\frac{|p_i - \bar{p}|}{s_P}\right) < \frac{1}{2n}$$

# Критерий Шовене (Chauvenet)

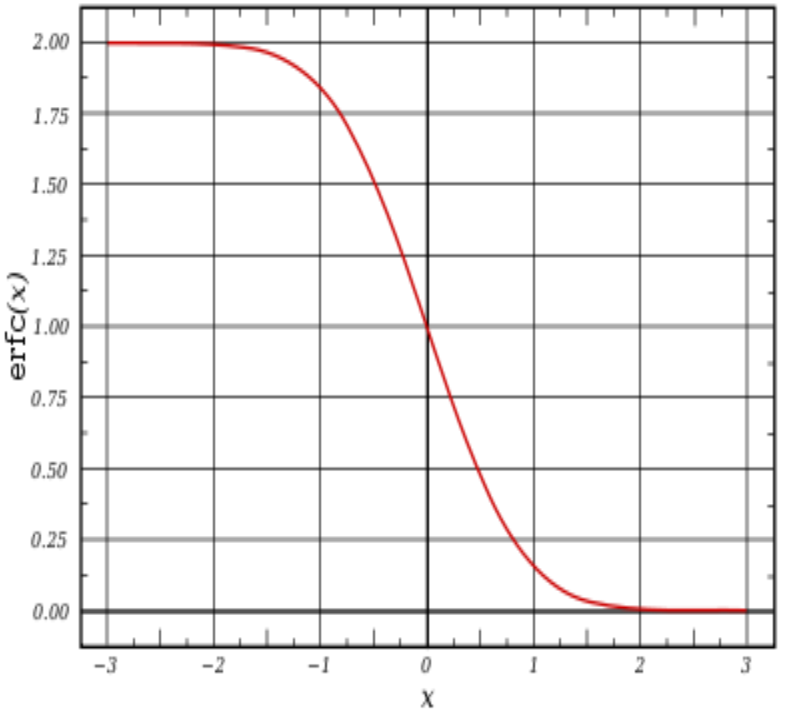
Значение $p_i$ является выбросом, если выполнено неравенство

$$erfc\left(\frac{|p_i - \bar{p}|}{s_P}\right) < \frac{1}{2n}$$

где

$$erfc(x) = \frac{2}{\sqrt{\pi}} \int_x^{\infty} e^{-t} dt$$

дополнение к функции ошибок.



# Пример

Есть *n=14* объектов со следующими значениями признака *P*

8.02 8.16 3.97 8.64 0.84 4.46 0.81 7.74 8.78 9.26 20.46 29.87 10.38 25.71

Вычисляем: $\bar{p}$ =10.51, $S_P$ =8.77.

Проверка для 25.71:

$$erfc\left(\frac{|25.71-10.51|}{8.77}\right)=0.014<0.036=\frac{1}{2*14}$$

то есть это выброс!!!

# Пример

Есть *n=14* объектов со следующими значениями признака *P*

8.02 8.16 3.97 8.64 0.84 4.46 0.81 7.74 8.78 9.26 20.46 29.87 10.38 25.71

Вычисляем: $\bar{p}$ =10.51, $S_P$ =8.77.

Проверка для 29.87 также говорит: «выброс». А вот 20.46 уже не выброс:

$$erfc\left(\frac{|20.46-10.51|}{8.77}\right)=0.11>0.036=\frac{1}{2*14}$$

# Пример (вторая итерация)

Осталось *n=12* объектов со следующими значениями признака *P*

8.02 8.16 3.97 8.64 0.84 4.46 0.81 7.74 8.78 9.26 20.46 10.38

Вычисляем: $\bar{p}$ =7.63, $S_P$ =5.17.

Проверка для 20.46:

$$erfc\left(\frac{|20.46-7.63|}{5.17}\right)=0.00045<0.042=\frac{1}{2*12}$$

то есть теперь 20.46 стало выбросом!!!

# Пример (вторая итерация)

Осталось *n=12* объектов со следующими значениями признака *P*

8.02 8.16 3.97 8.64 0.84 4.46 0.81 7.74 8.78 9.26 20.46 10.38

Вычисляем: $\bar{p}$ =7.63, $S_P$=5.17.

Проверка для 10.38:

$$erfc\left(\frac{|10.38-7.63|}{5.17}\right)=0.452>0.042=\frac{1}{2*12}$$

то есть 10.38 не выброс. Остальные числа также проходят проверку.

# Пример (третья итерация)

Осталось *n=11* объектов со следующими значениями признака *P*

8.02 8.16 3.97 8.64 0.84 4.46 0.81 7.74 8.78 9.26 10.38

Вычисляем: $\bar{p}$ =6.46, $S_P$=3.38.

Проверка для 10.38:

$$erfc\left(\frac{|10.38-6.46|}{3.38}\right)=0.1>0.045=\frac{1}{2*11}$$

то есть 10.38 не выброс. Остальные числа также проходят проверку. КОНЕЦ работы, так как новые выбросы не появляются.

# Настройка критерия Шовене

Значение $p_i$ является выбросом, если выполнено неравенство

$$erfc\left(\frac{|p_i - \bar{p}|}{s_P}\right) < \frac{1}{2n}$$

Константу 2 (в формуле) можно заменить на любую другую константу. Это сделает критерий более беспощадным (либо более лояльным) к выбросам.

# Поиск выбросов без использования среднего и отклонения

# Философское затруднение

Значения среднего и отклонения сильно чувствительны к наличию выбросов.

Таким образом, возникает замкнутый круг: мы ищем выбросы с помощью среднего и отклонения, чьи значения как раз и обусловлены наличием выбросов.

Возникает идея искать выбросы без использования величин, которые сильно зависят от выбросов.

# Критерий, основанный на квартилях выборки

1 ая квартиль $Q_{25}$: это такое число, что ровно 25% выборки меньше его.

2 ая квартиль $Q_{50}$: это такое число, что ровно 50% выборки меньше его (фактически это медиана).

3 ья квартиль $Q_{75}$: это такое число, что ровно 75% выборки меньше его.

Например, для выборки

(-10,0,1,2,4,5,5,6,7,100)

имеем $Q_{25}=1$ $Q_{50}=4.5$ (медиана) $Q_{75}=6$

Как быстро найти $Q_{25}$ ($Q_{75}$)? Нужно вычислить медиану и разбить выборку на две части: A={что меньше медианы}, B={что больше медианы}. Тогда $Q_{25}$ ($Q_{75}$) будет медианой в A (B).

Факт: 50% элементов выборки принадлежат интервалу $[Q_{25}, Q_{75}]$.

Идея: элементы, которые сильно далеки от интервала $[Q_{25}, Q_{75}]$ можно объявить выбросами.

# Поиск выбросов с помощью квартилей

Правило: если элемент не попадает в интервал

$$(Q_{25}-1.5*(Q_{75}-Q_{25}),\ Q_{75}+1.5*(Q_{75}-Q_{25})),$$

то он объявляется выбросом.

В примере (-5,0,1,2,4,5,5,6,7,100) получаем $Q_{25}=1$, $Q_{75}=6$

Интервал будет такой: (1-1.5*5, 6+1.5*5)=

(-6.5,13.5).

Таким образом, элемент 100 – выброс.

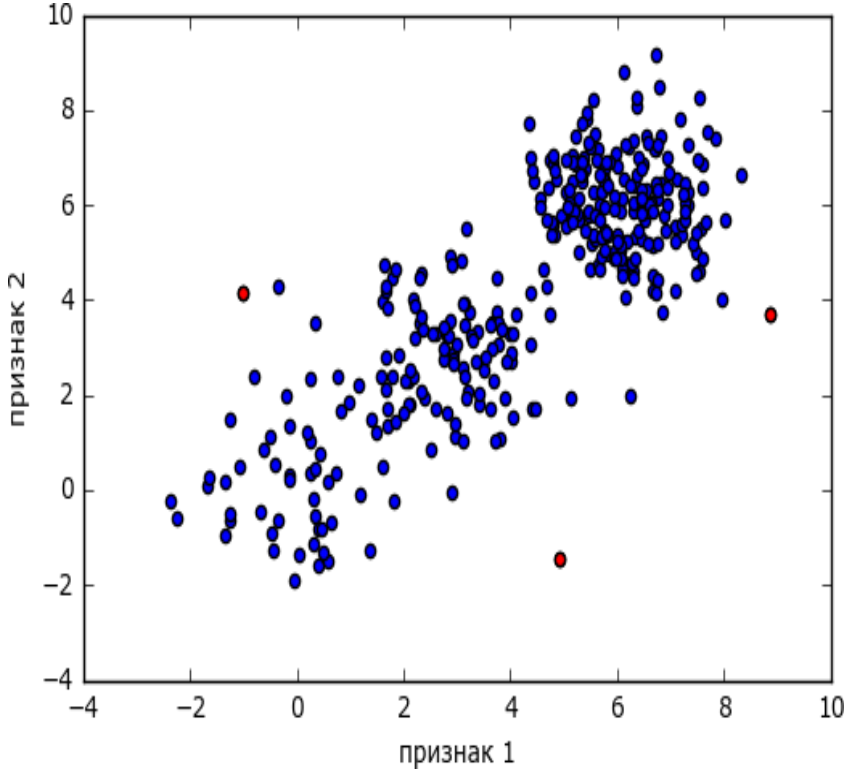
# Методы, анализирующие несколько признаков

## Недостатки методов, которые анализируют 1 признак (1-й недостаток)

В выборке (1, 50, 2, 1, 101, 2, 1, 100, 1, 3, 101, 1, 3, 100, 101, 100, 100) число 50, очевидно, аномально. Но поскольку 50 очень близко к среднему значению, то все описанные выше методы его не заметят.

# Недостатки методов, которые анализируют 1 признак (2-й недостаток)

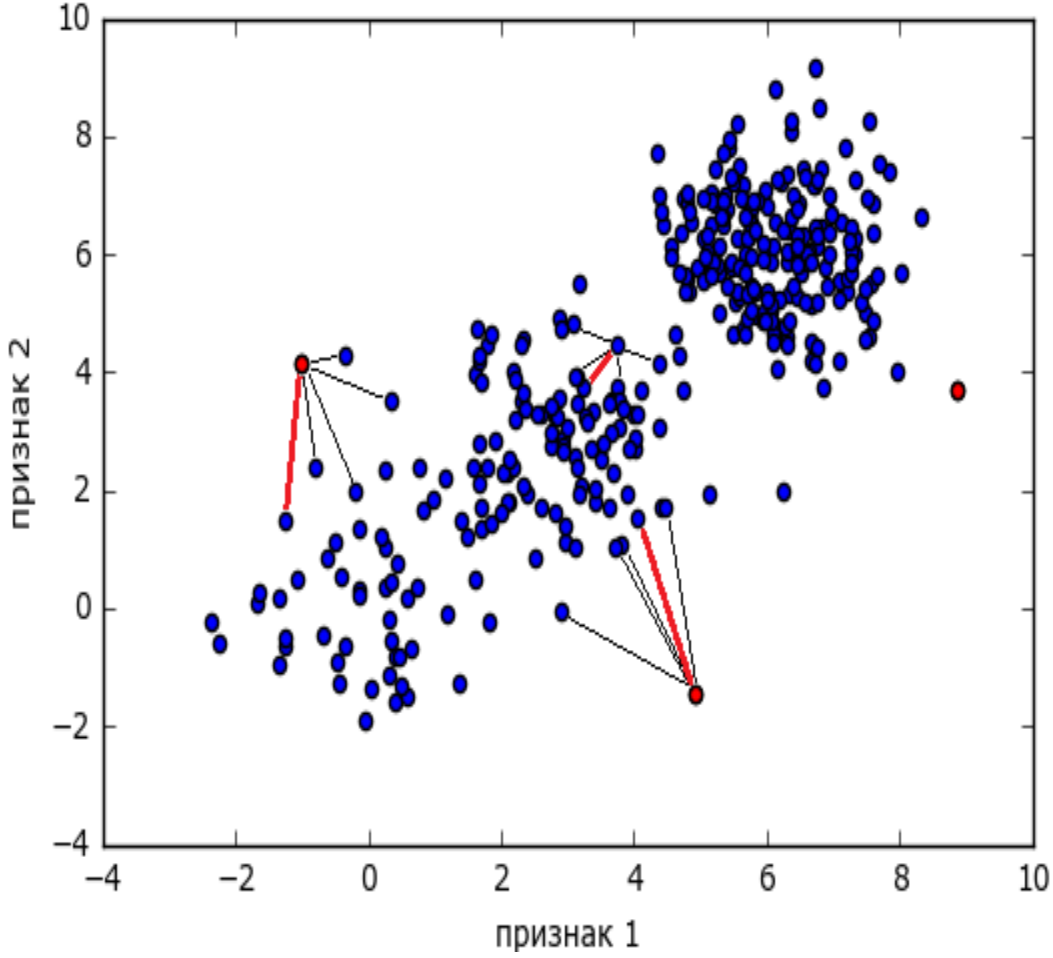
Аномалия часто характеризуется не только экстремальными значениями отдельных признаков. На картинке каждый выброс имеет «нормальное» значения каждого признака, но их комбинация приводит к аномалии.



# Метрические методы

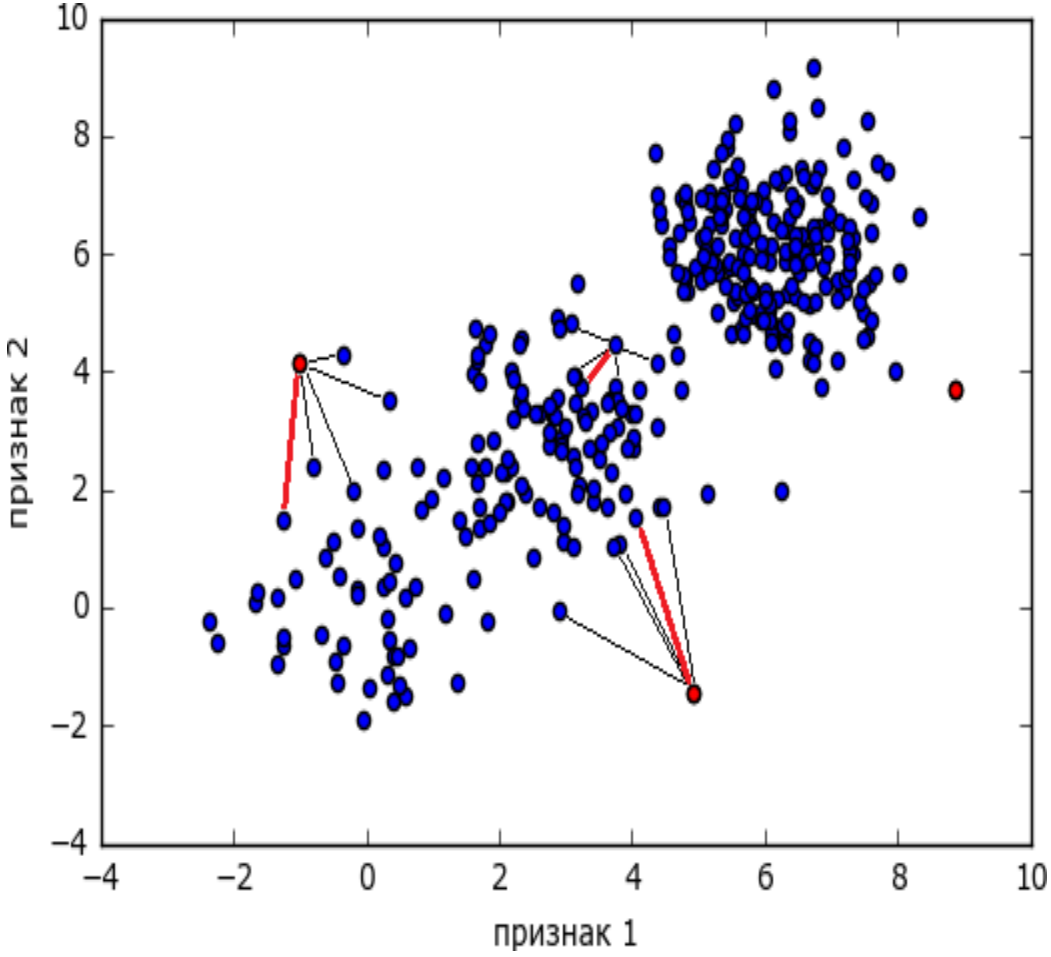
Представим объекты с $m$ признаками с помощью точек в пространстве $R^m$.

Идея: у выброса мало соседей, а у типичного объекта много.



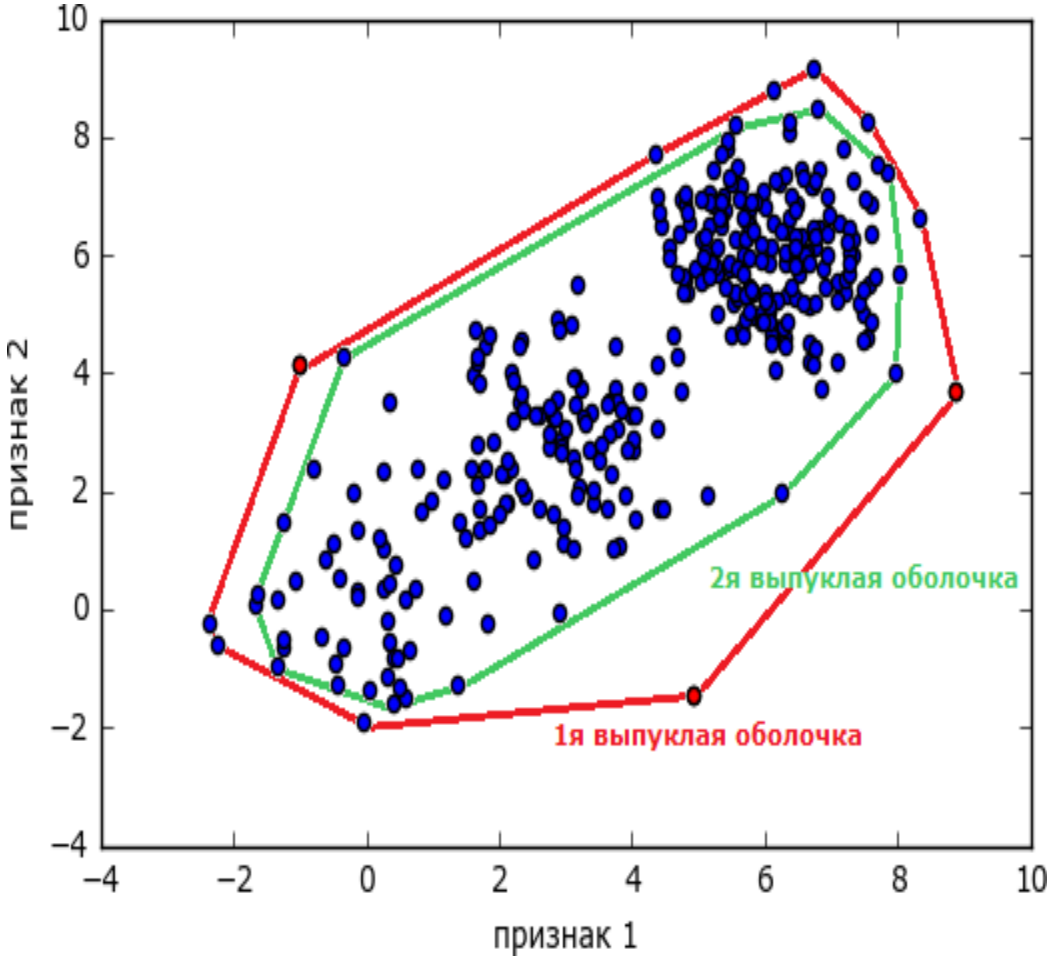
# Метрические методы

Можно найти расстояние от каждого объекта до его ближайшего соседа. У выбросов такое расстояние будет большим (можно предложить и другие варианты алгоритма).



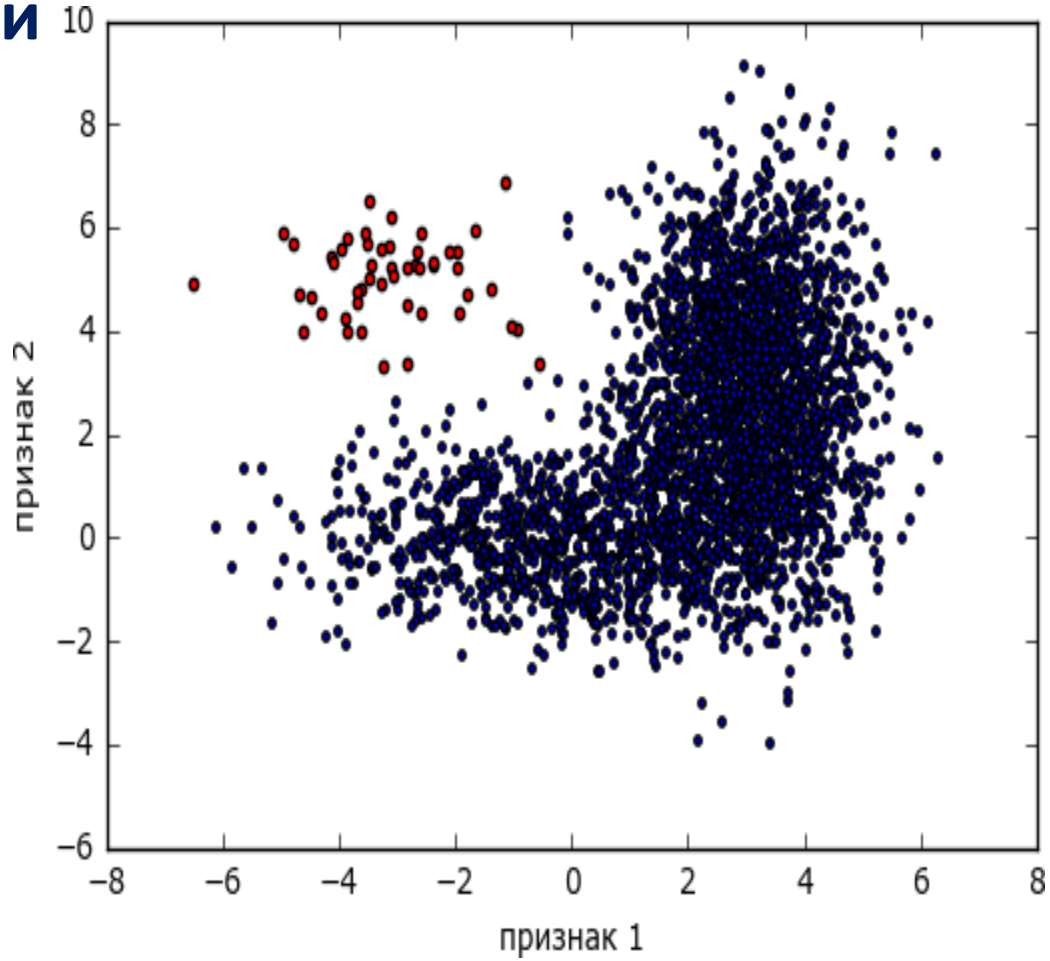
# Геометрические методы

Можно вычислить выпуклую оболочку объектов (как точек в m-мерном пространстве). Выбросами будут объекты на границе. Их можно удалить, а процедуру повторить еще несколько раз.



# Поиск выбросов с помощью кластеризации

Можно запустить алгоритм кластеризации
Он разобьет объекты на группы.
Выбросы – это элементы малых (в том числе и одноэлементных) групп.



## Поиск выбросов с помощью моделей предсказания

1) Некоторые вариации метода опорных векторов (SVM) позволяют находить выбросы.

2) Вариация решающих деревьев (decision trees) под названием «изолирующий лес» может искать выбросы.

## Поиск выбросов с помощью моделей предсказания

3) Можно запустить модель предсказания признака P по другим признакам таблицы. Объекты, для которых предсказанное и истинное значение P различаются очень сильно, можно объявить выбросами.

# Поиск новизны

## Поиск новизны можно свести к поиску выбросов

Есть множество объектов $M$. Определить, является ли объект $A \notin M$ похожим на объекты из $M$ или нет?

Переход к поиску выбросов: добавляем объект $A$ в множество $M$ и запускаем алгоритм поиска выброса. Если $A$ будет детектирован как выброс, то $A$ являлся новизной.

Но есть и алгоритмы, которые ищут новизну, не используя поиск выбросов.

# Поиск новизны без поиска выбросов

Строим выпуклую оболочку всех объектов из выборки. Объект А будет считаться новизной, если он НЕ попадает в эту выпуклую оболочку.

