Fuzzy C-Means

• Суть алгоритма

- В отличие от жесткого K-Means, где точка принадлежит только одному кластеру, FCM вводит понятие нечеткой принадлежности. В FCM у каждой точки есть степень принадлежности к каждому кластеру (от 0 до 1). Каждая точка может принадлежать всем кластерам одновременно, но с разной степенью (от 0 до 1). Сумма степеней принадлежности одной точки ко всем кластерам всегда равна 1.
- Это особенно полезно для данных, где границы между кластерами размыты.
- Алгоритм минимизирует взвешенную сумму квадратов расстояний до центроидов.

Целевая функция

$$J = \sum_{i=1}^{n} \sum_{j=1}^{c} (u_{ij})^m ||x_i - c_j||^2$$

где:

- n — количество точек данных
- c — количество кластеров
- u_{ij} — степень принадлежности точки i к кластеру j
- m — "коэффициент нечеткости" (обычно $m = 2$)
- x_i — i-я точка данных
- c_j — центр j-го кластера

- Пример: Кластеризация двух точек
- Данные: Всего две точки: $x_1 = 0$, $x_2 = 10$.
- Задача: Разбить на два кластера (c = 2).
- Параметр нечеткости: Возьмем (m = 2).
- **Шаг 1**
- Инициализация центроидов
- Выберем начальные положения центроидов случайным образом
- Возьмем: $c_1 = 0$, $c_2 = 10$ (совпадают с точками данных).

Шаг 2: Расчет матрицы принадлежностей (U)

Формула для обновления принадлежностей:

$$u_{ij} = \frac{1}{\sum_{k=1}^{c} \left(\frac{||x_i - c_j||}{||x_i - c_k||} \right)^{\frac{2}{m-1}}}$$

Так как $m = 2$, формула упрощается:

$$u_{ij} = \frac{1}{\sum_{k=1}^{c} \left(\frac{||x_i - c_j||}{||x_i - c_k||} \right)^{2}}$$

Считаем для точки $x_1 = 0$:

- Расстояния: $d_{11} = |0 - 0| = 0$, $d_{12} = |0 - 10| = 10$
- Для $j = 1$: $u_{11} = \frac{1}{\left(\frac{0}{0}\right)^2 + \left(\frac{0}{10}\right)^2}$ → Делим на ноль!

Проблема: Если расстояние до центра кластера равно 0, то точка полностью ему принадлежит.

Формально, если $d_{ij} = 0$, то $u_{ij} = 1$, а все другие $u_{ik} = 0$ для $k \neq j$.

Пересчитаем корректно:

Для точки $x_1 = 0$:

- $d_{11} = 0$, $d_{12} = 10$
- Так как $d_{11} = 0$, назначаем: $u_{11} = 1$, $u_{12} = 0$

- Для точки x2 = 10
- d{21} = 10 , d{22} = 0
- Так как d{22} = 0, назначаем: u{21} = 0, u{22} = 1

Получаем **матрицу принадлежностей U**:

$$U = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

- Это тривиальный случай, когда точки совпали с центрами. Возьмем другие начальные центры, чтобы пример был более показательным.

Пример 2

Данные: $x_1 = 0$, $x_2 = 10$.
Начальные центроиды: $c_1 = 3$, $c_2 = 7$.
Параметр: $m = 2$.

Итерация 1: Расчет принадлежностей
1. Считаем расстояния от всех точек до всех центров:
d{11} = |0-3| = 3
d{12} = |0-7| = 7
d{21} = |10-3| = 7
d{22} = |10-7| = 3

2. Расчет принадлежностей u_{ij}:

Формула: $u_{ij} = \frac{1}{\left(\frac{d_{ij}}{d_{i1}}\right)^2 + \left(\frac{d_{ij}}{d_{i2}}\right)^2}$

Для точки $x_1 = 0$:

- $u_{11} = \frac{1}{\left(\frac{3}{3}\right)^2 + \left(\frac{3}{7}\right)^2} = \frac{1}{1 + (0.4286)^2} = \frac{1}{1 + 0.1837} = \frac{1}{1.1837} \approx 0.845$
- $u_{12} = \frac{1}{\left(\frac{7}{3}\right)^2 + \left(\frac{7}{7}\right)^2} = \frac{1}{(2.333)^2 + 1} = \frac{1}{5.444 + 1} = \frac{1}{6.444} \approx 0.155$

Для точки $x_2 = 10$:

- $u_{21} = \frac{1}{\left(\frac{7}{7}\right)^2 + \left(\frac{7}{3}\right)^2} = \frac{1}{1 + (2.333)^2} = \frac{1}{1 + 5.444} = \frac{1}{6.444} \approx 0.155$
- $u_{22} = \frac{1}{\left(\frac{3}{7}\right)^2 + \left(\frac{3}{3}\right)^2} = \frac{1}{(0.4286)^2 + 1} = \frac{1}{0.1837 + 1} = \frac{1}{1.1837} \approx 0.845$

Новая матрица U:

$$U \approx \begin{bmatrix} 0.845 & 0.155 \\ 0.155 & 0.845 \end{bmatrix}$$

Итерация 1: Перерасчет центроидов

Формула для нового центра кластера j:

$$c_j = \frac{\sum_{i=1}^{n} (u_{ij})^m \cdot x_i}{\sum_{i=1}^{n} (u_{ij})^m}$$

Для кластера 1 (c_1):

- Числитель: $(0.845)^2 \cdot 0 + (0.155)^2 \cdot 10 = 0.714 \cdot 0 + 0.024 \cdot 10 = 0 + 0.24 = 0.24$
- Знаменатель: $(0.845)^2 + (0.155)^2 = 0.714 + 0.024 = 0.738$
- $c_1 = \frac{0.24}{0.738} \approx 0.325$

Для кластера 2 (c_2):

- Числитель: $(0.155)^2 \cdot 0 + (0.845)^2 \cdot 10 = 0.024 \cdot 0 + 0.714 \cdot 10 = 0 + 7.14 = 7.14$
- Знаменатель: $(0.155)^2 + (0.845)^2 = 0.024 + 0.714 = 0.738$
- $c_2 = \frac{7.14}{0.738} \approx 9.675$

Новые центроиды: $c_1 \approx 0.325$, $c_2 \approx 9.675$

Мы видим, что центры сдвинулись от начальных (3 и 7) ближе к реальным скоплениям точек (0 10).

Итерация 2 и далее

Алгоритм повторяет шаги 2 и 3 (расчет U и пересчет C) до тех пор, пока изменения центроидов не станут меньше заданного порога.

На второй итерации:

Расстояния будут считаться уже до новых центров (0.325 и 9.675).

Принадлежности для точки $x_1=0$ к первому кластеру станет еще выше (т.к. он теперь ближе), а для точки $x_2=10$ — ко второму.

Центры сдвинутся еще ближе к 0 и 10.

$c_1 \to 0, c_2 \to 10$

Матрица U станет практически единичной:

$$U \approx \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

Вывод

Этот простой пример показывает механизм FCM:

1. Принадлежности вычисляются на основе относительной близости точки к центрам кластеров.

2. Центры кластеров пересчитываются как взвешенное среднее всех точек, где веса — это степени принадлежности в степени m.

3. Процесс итеративный и продолжается до стабилизации.

Постановка задачи

Допустим, у нас есть 4 точки на прямой линии для простоты:

$x_1 = 1, x_2 = 2, x_3 = 5, x_4 = 6$

Мы хотим разбить их на C = 2 кластера.

Параметры:

C = 2 (количество кластеров)

m = 2 - коэффициент размытости, обычно m= 2. Чем он больше, тем размытее кластеры).

ε = 0.01 (точность, условие остановки)

Мы создаем матрицу U, где элемент u_{ij} — степень принадлежности точки i к кластеру j. Начинаем со случайных значений, главное, чтобы сумма по строке была равна 1.

Пусть наша начальная матрица U такая:

Точка	Кластер 1 (u_{i1})	Кластер 2 (u_{i2})	Сумма
$x_1 = 1$	0,8	0,2	1
$x_2 = 2$	0,9	0,1	1
$x_3 = 5$	0,1	0,9	1
$x_4 = 6$	0,2	0,8	1

изначально мы предположили, что x_1 и x_2 ближе к первому кластеру, а x_3 и x_4 — ко второму.

Шаг 2: Расчет центроидов кластеров

Центроиды рассчитываются не как простое среднее, а как взвешенное среднее, где веса — это степени принадлежности в степени m.

Формула для центроида j:

$$V_i = \frac{\sum_i u_{ij}^m \cdot x_i}{\sum_i u_{ij}^m}$$

Рассчитаем центроиды для нашей начальной U (m=2).

Для Кластера 1 (v_1):

Числитель = $0.8^2 \cdot 1 + 0.9^2 \cdot 2 + 0.1^2 \cdot 5 + 0.2^2 \cdot 6 = 0.64 \cdot 1 + 0.81 \cdot 2 + 0.01 \cdot 5 + 0.04 \cdot 6 = 0.64 + 1.62 + 0.05 + 0.24 = 2.55$

Знаменатель = $0.8^2 + 0.9^2 + 0.1^2 + 0.2^2 = 0.64 + 0.81 + 0.01 + 0.04 = 1.5$

- $v_1 = \frac{2.55}{1.5} \approx 1.7$

Для кластера 2 (v_2):

Числитель = $0.2^2 \cdot 1 + 0.1^2 \cdot 2 + 0.9^2 \cdot 5 + 0.8^2 \cdot 6 =$

$= 0.04 \cdot 1 + 0.01 \cdot 2 + 0.81 \cdot 5 + 0.64 \cdot 6 = 0.04 + 0.02 + 4.05 + 3.84 = 7.95$

Знаменатель = $0.2^2 + 0.1^2 + 0.9^2 + 0.8^2 = 0.04 + 0.01 + 0.81 + 0.64 = 1.5$

$$v_2 = \frac{7.95}{1.5} = 5.3$$

Итак, у нас получились центры кластеров: $v_1 \approx 1.7$ и $v_2 = 5.3$.

Шаг 3. Обновление матрицы принадлежностей U

Теперь, зная центроиды, мы пересчитаем, насколько каждая точка близка к каждому центру.

Формула для принадлежности: $u_i = \frac{1}{\sum_k \left(\frac{|x_i - v_j|}{|x_i - v_k|} \right)^{\frac{2}{m-1}}}$

Это выглядит сложно, но на практике для двух кластеров (C=2) и m=2 формула упрощается, так как $\frac{2}{m-1} = \frac{2}{2-1} = 2$.

Рассчитаем новую принадлежность для точки x_1 (1).

Расстояние до v_1: $d_{11} = |1 - 1.7| = 0.7$

Расстояние до v_2: $d_{12} = |1 - 5.3| = 4.3$

$$u_{11} = \frac{1}{\left(\frac{d_{11}}{d_{11}}\right)^2 + \left(\frac{d_{11}}{d_{12}}\right)^2} = \frac{1}{1 + \frac{0.7^2}{4.3^2}} \approx 0.974$$

используется формула для C=2

$u_{12} = 1 - u_{11} \approx 1 - 0.974 = 0.026$` (так как сумма должна быть 1)

После пересчета точка x_1 стала "сильнее" принадлежать Кластеру 1 (0.974 против изначальных 0.8).

Аналогично пересчитываются все остальные точки. После пересчета новая матрица U будет иметь вид:

$\boldsymbol{x_1 = 1}$	**0,974**	**0,026**	**1**
x_2 =2	0,93	0,07	1
$\boldsymbol{x_3 = 5}$	0,07	0,93	1
$\boldsymbol{x_4 = 6}$	0,03	0,97	1

Шаг 4. Проверка условия остановки

Алгоритм итерационный. Мы повторяем шаги 2 и 3, пока изменения в матрице U (или в центроидах) не станут меньше заданного порога ε.

Например, мы сравниваем норму разности между старой U и новой U. Если она меньше ε = 0.01, алгоритм останавливается.

В этом простом примере после одной-двух итераций изменения уже будут очень малы.

Финальный результат

После нескольких итераций алгоритм сойдется.

Итоговые центроиды:

v_1 будет около 1.5 (среднее между 1 и 2)

v_2 будет около 5.5 (среднее между 5 и 6)

- Итоговая матрица принадлежностей U:

Точка	Кластер 1	Кластер 2	Сумма
$x_1 = 1$	0,99	0,01	1
$x_2 = 2$	0,95	0,05	1
$x_3 = 5$	0,05	0,95	1
$x_4 = 6$	0,01	0,99	1

Пояснение и интерпретация

1. Мы не говорим: «x_2 принадлежит Кластеру 1». Мы говорим: «x_2 принадлежит Кластеру 1 со степенью 0.95, а Кластеру 2 со степенью 0.05». Это более гибкая и информативная модель.

2. Алгоритм четко разделил наши точки на два кластера: {1, 2} и {5, 6}.

3. Если бы у нас была точка x=3.5, FCM присвоил бы ей, например, u~0.5 и u~0.5, правильно указав на ее неопределенную принадлежность, в то время как K-Means жестко отнес бы ее к одному из кластеров.

Таким образом, FCM отлично подходит для задач, где данные перекрываются и нет четких границ между группами.